INSTITUCIÓN UNIVERSITARIA ITM

INFORME FINAL
TALLER EVALUATIVO 2

Proceso ETL con los datasets de Airbnb Bogotá

Inteligencia de negocios

Estudiante: Robin Alexander Montoya Velasquez
Modalidad: trabajo individual
Fecha: 11/10/2026
Bogotá, Colombia

1. Introducción

Este trabajo implementa un flujo ETL en Python para explorar y preparar los datos de alojamientos, reseñas y calendario de Airbnb en Bogotá. La fuente de extracción es MongoDB local, no los CSV directamente. El desarrollo y la documentación fueron realizados individualmente por el estudiante indicado en la portada.

2. Descripción de la fuente

La base consultada es bogota. Las columnas de negocio provienen de los datasets de Bogotá; MongoDB agrega el campo técnico _id, conservado como identificador y excluido de la comparación de duplicados.

Colección	Registros	Campos fuente	Campos MongoDB
Alojamientos (Listings)	19.187	90	91
Reseñas (Reviews)	527.731	6	7
Calendario (Calendar)	7.003.255	5	6

3. Análisis exploratorio y hallazgos

Listings contiene información de precios, anfitriones, características y disponibilidad. Reviews es una colección de eventos asociados a anuncios; Calendar contiene una fila por anuncio y fecha. Por ello, Calendar concentra la mayor parte del volumen y requiere procesamiento por bloques.

Calidad de datos

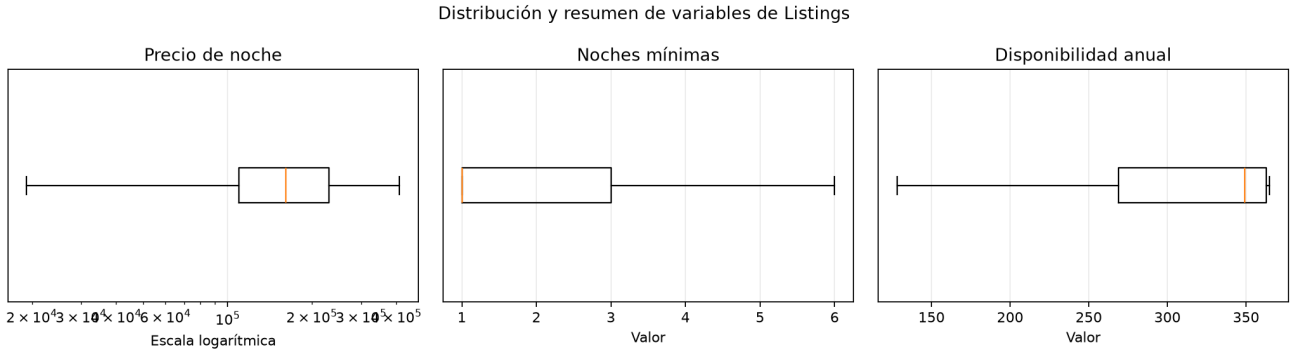
Colección	Celdas nulas	Columnas con nulos
Alojamientos (Listings)	295.610	46
Reseñas (Reviews)	0	0
Calendario (Calendar)	0	0

Los nulos parciales se conservan para no perder observaciones válidas de otras variables. La detección de duplicados se realiza ignorando el _id técnico de MongoDB; al actualizar ese criterio deben regenerarse las salidas del Notebook antes de reportar un conteo de duplicados.

Valores atípicos en Listings

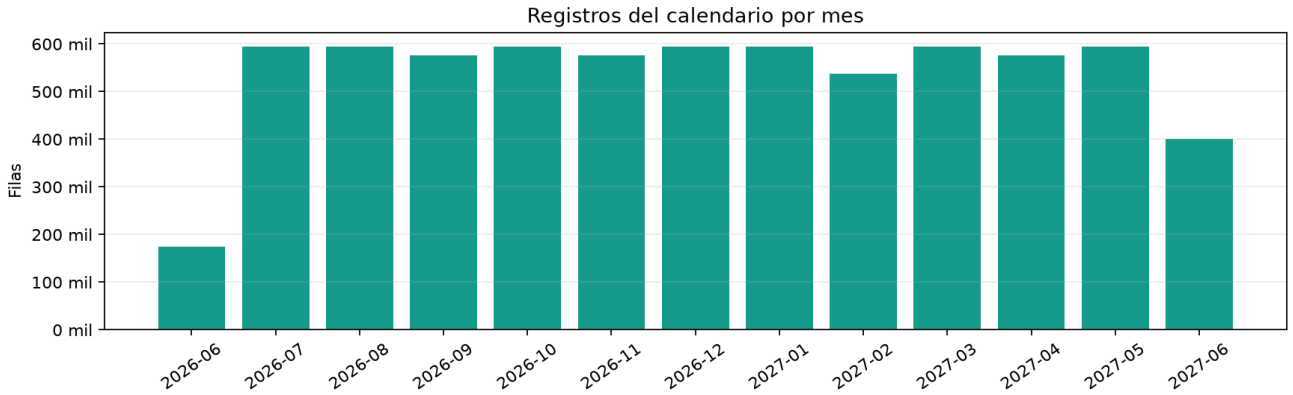
Variable	Válidos	Nulos	Mediana	Máximo	Atípicos IQR
Precio (COP)	18.992	195	161.460,00	448.176.567,00	1.410
Noches mínimas	19.183	4	1,00	32,00	4.053
Disponibilidad 365	19.187	0	349,00	365,00	1.129

El criterio IQR marca observaciones para revisión, no errores automáticos. En particular, el precio máximo muy superior al tercer cuartil debe validarse con su moneda, unidad y valor original antes de excluirlo. La disponibilidad baja también puede ser un estado real del anuncio.



Los bigotes llegan al mínimo y máximo dentro de los límites IQR; los conteos de valores fuera de esos límites aparecen en la tabla. El eje del precio es logarítmico para distinguir valores centrales frente a la cola larga.

Cobertura temporal de Calendar



La cobertura observada va de 2026-06 a 2027-06. Las diferencias mensuales reflejan la cobertura del calendario y sus fechas, no necesariamente cambios en demanda.

4. Transformaciones implementadas

El proceso limpia filas totalmente vacías y duplicados exactos (sin comparar el identificador técnico _id), elimina columnas totalmente nulas y conserva nulos parciales. Los documentos anidados se aplanan, las listas se serializan en JSON y amenities_count resume la cantidad de servicios.

El campo price se normaliza a valor numérico, quitando símbolos monetarios y separadores; los valores no interpretables generan advertencias. Las fechas pasan al formato YYYY-MM-DD y, para date, se derivan año, mes, día y trimestre. El precio se agrupa por terciles calculados sobre los valores válidos.

La ejecución principal procesa MongoDB por bloques. SQLite se verifica contra el total transformado y cada XLSX se escribe en modo de bajo uso de memoria, creando hojas adicionales al alcanzar el máximo de filas de Excel.

5. Evidencia de ejecución y validación

La evidencia disponible confirma conexión y extracción, pero no un ciclo ETL completo con SQLite y XLSX. Ejecuta `python -m src.main` y vuelve a generar este informe antes de entregar si las salidas no existen.

```
2026-10-11 11:06:17 | INFO | Conexión a MongoDB exitosa; base de datos: bogota
2026-10-11 11:06:19 | INFO | Colección Listings extraída: 19187 registros
2026-10-11 11:06:24 | INFO | Colección Reviews extraída: 527731 registros
2026-10-11 11:07:22 | INFO | Colección Calendar extraída: 7003255 registros
```

Las pruebas unitarias del proyecto cubren extracción, transformación, carga a SQLite, escritura XLSX por bloques y división de hojas. La validación integral sobre todas las 7.003.255 filas de Calendar debe confirmarse con el log de finalización y los artefactos de salida, no solo con el log de extracción.

6. Conclusiones

Las tres colecciones tienen utilidad analítica complementaria: Listings permite describir oferta y precios; Reviews permite estudiar actividad y experiencia; Calendar permite analizar disponibilidad en el tiempo. La cantidad de datos y la dispersión de precio exigen procesos reproducibles y validaciones explícitas.

La limpieza conserva la información parcial en vez de descartar filas completas. Los valores atípicos se documentan pero no se eliminan sin contexto de negocio. El procesamiento por bloques y la exportación en varias hojas responden al volumen real encontrado en MongoDB.

7. Referencias

• Institución Universitaria ITM. Taller evaluativo 2: Proceso ETL con los datasets de Airbnb Bogotá (guía entregada para el curso).
• Inside Airbnb. Datasets detallados de Listings, Calendar y Reviews para Bogotá, Colombia (archivos fuente indicados en la guía).
• MongoDB Documentation. Manual de consultas y cursores.
• pandas Documentation. Manual de DataFrames y limpieza de datos.